

تمرین ۱ از کتاب مورفی E۲.۳

Sum a of Variance :۳.۲ Exercise

ما می‌خواهیم نشان دهیم که واریانس مجموع دو متغیر تصادفی X و Y به صورت زیر است:

$$\text{var}[X + Y] = \text{var}[X] + \text{var}[Y] + 2 \text{cov}[X, Y]$$

تعریف واریانس برای یک متغیر تصادفی Z عبارت است از:

$$\text{var}[Z] = \mathbb{E}[(Z - \mathbb{E}[Z])^2]$$

این را برای $Z = X + Y$ اعمال می‌کنیم:

$$\text{var}[X + Y] = \mathbb{E}[(X + Y - \mathbb{E}[X + Y])^2]$$

با استفاده از خطی بودن امید ریاضی، $\mathbb{E}[X + Y] = \mathbb{E}[X] + \mathbb{E}[Y]$ ، بنابراین:

$$\text{var}[X + Y] = \mathbb{E}[(X - \mathbb{E}[X] + Y - \mathbb{E}[Y])^2]$$

حالا مربع را بسط می‌دهیم:

$$= \mathbb{E}[(X - \mathbb{E}[X])^2 + (Y - \mathbb{E}[Y])^2 + 2(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

با استفاده از خطی بودن امید ریاضی، این عبارت را به سه جمله تقسیم می‌کنیم:

$$= \mathbb{E}[(X - \mathbb{E}[X])^2] + \mathbb{E}[(Y - \mathbb{E}[Y])^2] + 2 \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

هر جمله را تشخیص می‌دهیم:

$$\mathbb{E}[(X - \mathbb{E}[X])^2] = \text{var}[X] \bullet$$

$$\mathbb{E}[(Y - \mathbb{E}[Y])^2] = \text{var}[Y] \bullet$$

$$\mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \text{cov}[X, Y] \bullet$$

بنابراین،

$$\boxed{\text{var}[X + Y] = \text{var}[X] + \text{var}[Y] + 2 \text{cov}[X, Y]}$$

تمرین ۱ از کتاب مورفی E۲.۶

ما یک متغیر تصادفی گسسته $H \in \{1, \dots, K\}$ و مقادیر مشاهده شده e_1, e_2 از دو متغیر تصادفی دیگر E_1, E_2 داریم. می‌خواهیم بردار احتمال را محاسبه کنیم:

$$\vec{P}(H|e_1, e_2) = (P(H=1|e_1, e_2), \dots, P(H=K|e_1, e_2))$$

این یک مسئله استاندارد استنباط بیز است. از قانون بیز استفاده می‌کنیم:

$$P(H=h|e_1, e_2) = \frac{P(e_1, e_2|H=h) \cdot P(H=h)}{P(e_1, e_2)}$$

مخرج $P(e_1, e_2)$ یک ثابت نرمال‌ساز (برای همه h ها یکسان) است، بنابراین می‌توانیم غیرنرمال‌شده را به صورت زیر محاسبه کنیم:

$$P(H=h|e_1, e_2) \propto P(e_1, e_2|H=h) \cdot P(H=h)$$

بخش (الف)

کدامیک از مجموعه‌های زیر برای محاسبه $\vec{P}(H|e_1, e_2)$ کافی هستند:

i. $P(e_1, e_2), P(H), P(e_1|H), P(e_2|H)$

ii. $P(e_1, e_2), P(H), P(e_1, e_2|H)$

iii. $P(e_1|H), P(e_2|H), P(H)$

بررسی هرکدام:

• **مجموعه (i):** ما $P(e_1|H)$ و $P(e_2|H)$ را داریم، اما $P(e_1, e_2|H)$ را نداریم. بدون فرض استقلال، نمی‌توانیم $P(e_1, e_2|H)$ را فقط از $P(e_1|H)$ و $P(e_2|H)$ محاسبه کنیم — مگر اینکه مستقل شرطی باشند، که در بخش (الف) فرض نشده است. بنابراین مجموعه (i) کافی نیست.

• **مجموعه (ii):** ما $P(e_1, e_2|H)$ و $P(H)$ را داریم که مستقیماً صورت قانون بیز را می‌دهد: $P(e_1, e_2|H)P(H=h)$. مخرج $P(e_1, e_2)$ نیز داده شده است، بنابراین می‌توانیم نرمال‌سازی کنیم. پس مجموعه (ii) کافی است.

• **مجموعه (iii):** ما $P(e_1|H), P(e_2|H), P(H)$ را داریم، اما دوباره هیچ توزیع توأمی $P(e_1, e_2|H)$ وجود ندارد و فرض استقلال شرطی نیز نشده است. بنابراین نمی‌توانیم $P(e_1, e_2|H)$ را محاسبه کنیم. لذا مجموعه (iii) کافی نیست.

پاسخ بخش (الف): فقط مجموعه (ii) کافی است.

بخش (ب)

حال فرض کنید استقلال شرطی وجود دارد: $E_1 \perp E_2 | H$ ، یعنی:

$$P(e_1, e_2|H=h) = P(e_1|H=h) \cdot P(e_2|H=h)$$

با این فرض، مجموعه‌ها را دوباره بررسی می‌کنیم:

• **مجموعه (i):** حالا ما $P(e_1|H), P(e_2|H), P(H)$ را داریم و از آنجا که $P(e_1, e_2|H) = P(e_1|H)P(e_2|H)$ می‌توانیم صورت را محاسبه کنیم. اما $P(e_1, e_2)$ را نداریم — مخرج. با این حال، چون فقط به نسبت‌های نسبی (برای نرمال‌سازی بردار پسین) نیاز داریم، می‌توانیم پسین‌های غیرنرمال‌شده را محاسبه کرده و سپس با جمع زدن روی h ، نرمال‌سازی کنیم. بنابراین نیازی به $P(e_1, e_2)$ به صورت صریح نیست — این مقدار در نرمال‌سازی حذف می‌شود.

بنابراین، با فرض استقلال شرطی، مجموعه (i) کافی می‌شود.

• **مجموعه (ii):** همچنان کافی است — همانند قبل.

• **مجموعه (iii):** مشابه (i) — ما $P(e_1|H), P(e_2|H), P(H)$ را داریم و تحت استقلال شرطی، می‌توانیم $P(e_1, e_2|H) = P(e_1|H)P(e_2|H)$ را محاسبه کنیم، بنابراین پسین غیرنرمال‌شده قابل محاسبه است. دوباره، نیازی به $P(e_1, e_2)$ نیست چون می‌توانیم داخلی نرمال‌سازی کنیم.

پاسخ بخش (ب): تمام سه مجموعه (i)، (ii)، (iii) کافی هستند.

جمع‌بندی نهایی

• (الف) فقط مجموعه (ii) کافی است.

• (ب) تحت استقلال شرطی، همه سه مجموعه (i)، (ii)، (iii) کافی هستند.

تمرین ۱ از کتاب مورفی E۲.۷

ما می‌خواهیم نشان دهیم که استقلال زوج‌به‌زوج بین تمام جفت متغیرها لزوماً به معنای استقلال متقابل نیست. یعنی حتی اگر هر جفت از متغیرها مستقل باشند، ممکن است مجموعه کامل متغیرها مستقل متقابل نباشند.

مرور تعاریف

• استقلال زوج‌به‌زوج (برای دو متغیر): $p(X_2|X_1) = p(X_2)$ که نتیجه می‌دهد $p(X_1, X_2) = p(X_1)p(X_2)$.

• استقلال متقابل (برای n متغیر): برای هر متغیر X_i و هر زیرمجموعه $S \subseteq \{1, \dots, n\} \setminus \{i\}$ ، داریم:

$$p(X_i|X_S) = p(X_i)$$

این بدین معناست که توزیع توأم به صورت کامل عامل‌بندی می‌شود:

$$p(X_1, \dots, X_n) = \prod_{i=1}^n p(X_i)$$

مثال نقض

یک مثال ساده با سه متغیر تصادفی دودویی X_1, X_2, X_3 که هر کدام مقادیر $\{0, 1\}$ را می‌گیرند، می‌سازیم. توزیع توأم آن‌ها را به شرح زیر تعریف می‌کنیم:

احتمال	X_3	X_2	X_1
$1/4$	۰	۰	۰
$1/4$	۱	۱	۰
$1/4$	۱	۰	۱
$1/4$	۰	۱	۱

همه ترکیبات دیگر احتمال صفر دارند.
این توزیع یکنواخت روی چهار حالتی است که در آن $X_1 \oplus X_2 \oplus X_3 = 0$ (یعنی XOR سه متغیر صفر است).
(است).

بررسی استقلال زوج به زوج

بررسی می‌کنیم که آیا هر جفت مستقل است یا خیر.

بررسی X_1 و X_2 :

توزیع حاشیه‌ای X_1 :

$$P(X_1 = 0) = P(0, 0, 0) + P(0, 1, 1) = 1/4 + 1/4 = 1/2 \bullet$$

$$P(X_1 = 1) = 1/2 \bullet$$

توزیع حاشیه‌ای X_2 :

$$P(X_2 = 0) = P(0, 0, 0) + P(1, 0, 1) = 1/4 + 1/4 = 1/2 \bullet$$

$$P(X_2 = 1) = 1/2 \bullet$$

توزیع توأم $P(X_1, X_2)$:

$$P(0, 0) = P(0, 0, 0) = 1/4 \bullet$$

$$P(0, 1) = P(0, 1, 1) = 1/4 \bullet$$

$$P(1, 0) = P(1, 0, 1) = 1/4 \bullet$$

$$P(1, 1) = P(1, 1, 0) = 1/4 \bullet$$

حال بررسی می‌کنیم که آیا $P(X_1, X_2) = P(X_1)P(X_2)$:

$$P(0, 0) = 1/4 = (1/2)(1/2) \quad \square \text{ درست} \bullet$$

• برای سایر حالات نیز مشابه $\square$ همه مطابقت دارند.

بنابراین $X_1 \perp X_2$.

با تقارن، $X_1 \perp X_3$ و $X_2 \perp X_3$ نیز برقرار است.

بنابراین همه جفت‌ها زوج به زوج مستقل هستند.

بررسی استقلال متقابل

برای استقلال متقابل، باید داشته باشیم:

$$p(X_1, X_2, X_3) = p(X_1)p(X_2)p(X_3)$$

توزیع‌های حاشیه‌ای:

$$\bullet \text{ هر } P(X_i = 1) = 1/2, P(X_i = 0) = 1/2$$

پس برای هر ترکیب، مثلاً $(0, 0, 0)$:

$$\bullet p(X_1 = 0)p(X_2 = 0)p(X_3 = 0) = (1/2)^3 = 1/8$$

اما از توزیع توأم ما، $P(X_1 = 0, X_2 = 0, X_3 = 0) = 1/4 \neq 1/8$
بنابراین استقلال متقابل برقرار نیست.

نتیجه گیری

ما یک توزیع توأم برای سه متغیر ساختیم که در آن هر جفت مستقل است، اما مجموعه کامل مستقل متقابل نیست. بنابراین، استقلال زوج به زوج لزوماً به معنای استقلال متقابل نیست.

تمرین ۱ از کتاب مورفی E۲.۱۲

ما می‌خواهیم نشان دهیم که اطلاعات متقابل $I(X, Y)$ را می‌توان به صورت زیر بر حسب انتروپی‌ها بیان کرد:

$$I(X, Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

مرور تعاریف

• اطلاعات متقابل (بین دو متغیر تصادفی X و Y):

$$I(X; Y) = \sum_x \sum_y p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

• انتروپی X :

$$H(X) = - \sum_x p(x) \log p(x)$$

• انتروپی شرطی X به شرط Y :

$$H(X|Y) = - \sum_y p(y) \sum_x p(x|y) \log p(x|y) = - \sum_{x,y} p(x, y) \log p(x|y)$$

اثبات

میدانیم:

$$I(X; Y) = \sum_{x,y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

در لگاریتم تقسیم تبدیل به منها میشود:

$$= \sum_{x,y} p(x, y) [\log p(x, y) - \log p(x) - \log p(y)]$$

پس:

$$= \sum_{x,y} p(x, y) \log p(x, y) - \sum_{x,y} p(x, y) \log p(x) - \sum_{x,y} p(x, y) \log p(y)$$

حال هر جمله را جداگانه بررسی می‌کنیم.

• جمله اول: $\sum_{x,y} p(x, y) \log p(x, y) = -H(X, Y)$ — این انتروپی X و Y است.

در واقع، طبق تعریف، $H(X, Y) = - \sum_{x,y} p(x, y) \log p(x, y)$ ، بنابراین:

$$\sum_{x,y} p(x, y) \log p(x, y) = -H(X, Y)$$

● جمله دوم: $\sum_{x,y} p(x,y) \log p(x) = \sum_x \log p(x) \sum_y p(x,y) = \sum_x \log p(x) \cdot p(x) = -H(X)$ چون $\sum_y p(x,y) = p(x)$ ، پس:

$$\sum_{x,y} p(x,y) \log p(x) = \sum_x p(x) \log p(x) = -H(X)$$

● جمله سوم: $\sum_{x,y} p(x,y) \log p(y) = \sum_y \log p(y) \sum_x p(x,y) = \sum_y \log p(y) \cdot p(y) = -H(Y)$ همه جملات را با هم جمع می‌کنیم:

$$I(X; Y) = [-H(X, Y)] - [-H(X)] - [-H(Y)]$$

$$= -H(X, Y) + H(X) + H(Y)$$

بنابراین،

$$I(X; Y) = H(X) + H(Y) - H(X, Y)$$

این یک هویت استاندارد است.

پس: $I(X; Y) = H(X) - H(X|Y)$

قانون زنجیره‌ای برای انتروپی:

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y)$$

از $H(X, Y) = H(Y) + H(X|Y)$ استفاده می‌کنیم و در عبارت اطلاعات جایگذاری می‌کنیم:

$$I(X; Y) = H(X) + H(Y) - H(X, Y) = H(X) + H(Y) - [H(Y) + H(X|Y)] = H(X) - H(X|Y)$$

به طور مشابه، با استفاده از $H(X, Y) = H(X) + H(Y|X)$:

$$I(X; Y) = H(X) + H(Y) - [H(X) + H(Y|X)] = H(Y) - H(Y|X)$$

نتیجه نهایی

$$I(X; Y) = H(X) - H(X|Y) = H(Y) - H(Y|X)$$

تمرین ۱ از کتاب مورفی E۲.۱۵

ما داریم:

● $p_{\text{emp}}(x)$: توزیع تجربی — توزیعی که جرم احتمال را متناسب با فراوانی هر نقطه داده در مجموعه آموزشی اختصاص می‌دهد.

● $q(x|\theta)$: یک مدل پارامتری با پارامتر θ .

ما باید نشان دهیم که تخمین حداکثر **likelihood (MLE)** $\hat{\theta}$ ، واگرایی کولبک-لایبلر (KL) بین توزیع تجربی و مدل را به حداقل می‌رساند:

$$\arg \min_q \text{KL}(p_{\text{emp}} \| q) = q(x; \hat{\theta})$$

که در آن $\hat{\theta}$ تخمین MLE است.

مرحله ۱: تعریف واگرایی KL

واگرایی KL از p_{emp} به q عبارت است از:

$$\text{KL}(p_{\text{emp}} \| q) = \sum_x p_{\text{emp}}(x) \log \frac{p_{\text{emp}}(x)}{q(x|\theta)}$$

این را می‌توان بازنویسی کرد:

$$= \sum_x p_{\text{emp}}(x) \log p_{\text{emp}}(x) - \sum_x p_{\text{emp}}(x) \log q(x|\theta)$$

توجه کنید که جمله اول، $\sum_x p_{\text{emp}}(x) \log p_{\text{emp}}(x)$ ، ثابت است نسبت به θ — فقط به داده‌ها بستگی دارد، نه به پارامترهای مدل. بنابراین، حداقل‌سازی واگرایی KL معادل است با حداکثر کردن:

$$\sum_x p_{\text{emp}}(x) \log q(x|\theta)$$

مرحله ۲: ارتباط با لگاریتم likelihood

فرض کنید مجموعه داده $\mathcal{D} = \{x^{(1)}, x^{(2)}, \dots, x^{(N)}\}$ را داریم، که هر $x^{(i)}$ یک مشاهده است. توزیع تجربی به صورت زیر تعریف می‌شود:

$$p_{\text{emp}}(x) = \frac{1}{N} \sum_{i=1}^N \delta(x, x^{(i)})$$

که در آن $\delta(x, x^{(i)}) = 1$ اگر $x = x^{(i)}$ ، در غیر این صورت صفر است. به عبارت دیگر، برای متغیرهای گسسته، $p_{\text{emp}}(x)$ نسبت دفعات ظاهر شدن x در مجموعه داده است. سپس،

$$\sum_x p_{\text{emp}}(x) \log q(x|\theta) = \frac{1}{N} \sum_{i=1}^N \log q(x^{(i)}|\theta)$$

این دقیقاً میانگین لگاریتم **likelihood** روی مجموعه داده است.

بنابراین، حداقل‌سازی واگرایی KL $\text{KL}(p_{\text{emp}} \| q)$ معادل است با حداکثر کردن میانگین لگاریتم likelihood — که دقیقاً همان کاری است که MLE انجام می‌دهد.

مرحله ۳: استفاده از نامنفی بودن KL (راهنمایی)

راهنمایی پیشنهاد می‌کند از نامنفی بودن واگرایی KL استفاده کنیم.

به یاد داشته باشید: $\text{KL}(p \| q) \geq 0$ ، و تساوی فقط وقتی برقرار است که $p = q$.

در حالت ما، ما $\text{KL}(p_{\text{emp}} \| q)$ را روی $q \in \mathcal{Q}$ به حداقل می‌رسانیم، که در آن $\mathcal{Q}$ خانواده‌ای از توزیع‌ها است که با θ پارامتریزه شده‌اند.

تخمین MLE $\hat{\theta}$ مدل $q(x; \hat{\theta})$ را ارائه می‌دهد که بهترین تناسب را با داده‌ها دارد — یعنی $q(x|\hat{\theta})$ را به اندازه‌ای نزدیک به $p_{\text{emp}}(x)$ می‌کند. از آنجا که واگرایی KL ”فاصله” (اگرچه نامتقارن) را اندازه‌گیری می‌کند، حداقل‌سازی آن مدلی را پیدا می‌کند که تحت این معیار نزدیک‌ترین به توزیع تجربی است. بنابراین، با توجه به تعریف MLE و معادل بودن نشان داده شده، نتیجه می‌گیریم:

$$\boxed{\arg \min_q \text{KL}(p_{\text{emp}} \| q) = q(x; \hat{\theta})}$$

که در آن $\hat{\theta}$ تخمین MLE است.

نتیجه‌گیری

تخمین حداکثر **likelihood** معادل است با حداقل‌سازی واگرایی KL از توزیع تجربی به توزیع مدل.

تمرین ۲

تابع سیگموئید :

$$\sigma(a) = \frac{1}{1 + e^{-a}}$$

(الف) نشان دهیم که مشتق تابع سیگموئید برابر است با:

$$\frac{d\sigma(a)}{da} = \sigma(a)(1 - \sigma(a))$$

(ب) از این نتیجه برای محاسبه گرادیان تابع لگاریتم **likelihood** در رگرسیون لجستیک استفاده کنیم.

بخش (الف): مشتق تابع سیگموئید

با تعریف شروع می‌کنیم:

$$\sigma(a) = \frac{1}{1 + e^{-a}} = (1 + e^{-a})^{-1}$$

با استفاده از قاعده زنجیره‌ای مشتق می‌گیریم:
فرض کنید $u = 1 + e^{-a}$ ، بنابراین $\sigma(a) = u^{-1}$. پس:

$$\frac{d\sigma}{da} = \frac{d}{da}(u^{-1}) = -u^{-2} \cdot \frac{du}{da}$$

حالا $\frac{du}{da}$ را محاسبه می‌کنیم:

$$\frac{du}{da} = \frac{d}{da}(1 + e^{-a}) = -e^{-a}$$

بنابراین:

$$\frac{d\sigma}{da} = -(1 + e^{-a})^{-2} \cdot (-e^{-a}) = \frac{e^{-a}}{(1 + e^{-a})^2}$$

حالا این عبارت را بر حسب $\sigma(a)$ بازنویسی می‌کنیم:

به یاد داشته باشید:

$$\sigma(a) = \frac{1}{1 + e^{-a}} \Rightarrow 1 - \sigma(a) = 1 - \frac{1}{1 + e^{-a}} = \frac{e^{-a}}{1 + e^{-a}}$$

بنابراین:

$$\sigma(a)(1 - \sigma(a)) = \left(\frac{1}{1 + e^{-a}} \right) \left(\frac{e^{-a}}{1 + e^{-a}} \right) = \frac{e^{-a}}{(1 + e^{-a})^2}$$

که با عبارت قبلی برای $\frac{d\sigma}{da}$ مطابقت دارد.
بنابراین نشان داده شد:

$$\boxed{\frac{d\sigma(a)}{da} = \sigma(a)(1 - \sigma(a))}$$

بخش (ب): گرادیان تابع لگاریتم **likelihood** در رگرسیون لجستیک

در رگرسیون لجستیک، احتمال یک خروجی دودویی $y \in \{0, 1\}$ به شرط ورودی x را به صورت زیر مدل می‌کنیم:

$$p(y = 1|x; w) = \sigma(w^T x), \quad p(y = 0|x; w) = 1 - \sigma(w^T x)$$

احتمال برای یک نقطه داده (x, y) برابر است با:

$$p(y|x; w) = \sigma(w^T x)^y \cdot (1 - \sigma(w^T x))^{1-y}$$

لگاریتم **likelihood** برابر است با:

$$\ell(w) = \log p(y|x; w) = y \log \sigma(w^T x) + (1 - y) \log(1 - \sigma(w^T x))$$

ما می‌خواهیم گرادیان $\nabla_w \ell(w)$ را محاسبه کنیم.

فرض کنید $a = w^T x$ ، بنابراین $\sigma = \sigma(a)$.

پس:

$$\ell(w) = y \log \sigma + (1 - y) \log(1 - \sigma)$$

نسبت به w مشتق می‌گیریم:

$$\nabla_w \ell(w) = \left[y \cdot \frac{1}{\sigma} \cdot \frac{d\sigma}{da} + (1 - y) \cdot \frac{1}{1 - \sigma} \cdot \left(-\frac{d\sigma}{da} \right) \right] \cdot \nabla_w a$$

توجه کنید که $\nabla_w a = \nabla_w (w^T x) = x$.

همچنین، از بخش (الف)، $\frac{d\sigma}{da} = \sigma(1 - \sigma)$.

جایگذاری می‌کنیم:

$$\nabla_w \ell(w) = \left[y \cdot \frac{1}{\sigma} \cdot \sigma(1 - \sigma) - (1 - y) \cdot \frac{1}{1 - \sigma} \cdot \sigma(1 - \sigma) \right] \cdot x$$

عبارت داخل پرانتز را ساده می‌کنیم:

$$= [y(1 - \sigma) - (1 - y)\sigma] \cdot x$$

بسط می‌دهیم:

$$= [y - y\sigma - \sigma + y\sigma] \cdot x = [y - \sigma] \cdot x$$

بنابراین، گرادیان تابع لگاریتم likelihood برابر است با:

$$\nabla_w \ell(w) = (y - \sigma(w^T x)) \cdot x$$

تمرین ۳

این تمرین به رگرسیون لجستیک با منظم‌سازی L_2 می‌پردازد، که در آن تابع هدف به صورت زیر است:

$$J(\mathbf{w}) = -\ell(\mathbf{w}, D_{train}) + \lambda \|\mathbf{w}\|_2^2 \quad (\text{معادله ۱})$$

که در آن لگاریتم likelihood برای مجموعه داده D عبارت است از:

$$\ell(\mathbf{w}, D) = \frac{1}{|D|} \sum_{i \in D} \log \sigma(y_i \mathbf{x}_i^T \mathbf{w}), \quad y_i \in \{-1, +1\} \quad (\text{معادله ۸.۱۳۲.۲})$$

توجه: استفاده از $y_i \in \{-1, +1\}$ (به جای $\{0, 1\}$) در برخی فرمول‌بندی‌ها رایج است — این کار عبارت را متقارن می‌کند و محاسبه گرادیان را ساده‌تر می‌کند.
از ما خواسته شده است که به سوالات زیر پاسخ دهیم:

(الف) تابع $J(\mathbf{w})$ چه چیزی را به حداقل می‌رساند؟ طبقه‌بندی است یا رگرسیون؟

حداقل‌سازی $J(\mathbf{w})$ مربوط به طبقه‌بندی است، به طور خاص رگرسیون لجستیک با منظم‌سازی L_2 .

- جمله $-\ell(\mathbf{w}, D_{train})$ منفی لگاریتم likelihood است — حداقل‌سازی آن، likelihood مشاهده داده‌های آموزشی تحت مدل لجستیک را حداکثر می‌کند.
- جمله $\lambda \|\mathbf{w}\|_2^2$ یک جریمه L_2 (که به آن جریمه ریج نیز گفته می‌شود) است و باعث کوچک‌تر شدن وزن‌ها می‌شود تا از بیش‌برازش جلوگیری شود.
- از آنجا که ما $p(y = +1 | \mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x})$ را مدل می‌کنیم، این به طور بنیادی یک وظیفه طبقه‌بندی است.

بنابراین، حداقل‌سازی $J(\mathbf{w})$ مربوط به رگرسیون لجستیک منظم‌شده برای طبقه‌بندی دودویی است.

(ب) اگر $\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} J(\mathbf{w})$ باشد، آیا این جواب دارای بایاس صفر است؟

در رگرسیون لجستیک با منظم‌سازی L_2 ، جواب $\hat{\mathbf{w}}$ معمولاً عناصر صفر ندارد — یعنی پراکنده نیست.

- جریمه $\lambda \|\mathbf{w}\|_2^2 = \lambda \sum_j w_j^2$ ، وزن‌های بزرگ را جریمه می‌کند اما هیچ وزن فردی را دقیقاً به صفر نمی‌برد.
- در مقابل، منظم‌سازی L_1 (لاسو) باعث پراکندگی می‌شود و بسیاری از وزن‌ها را دقیقاً صفر می‌کند.
- بنابراین، مگر اینکه $\lambda \rightarrow \infty$ (که تمام وزن‌ها را به صفر می‌برد)، جواب منظم‌شده با L_2 معمولاً تمام وزن‌ها را غیرصفر دارد.

بنابراین، خیر، جواب بایاس صفر ندارد (در معنای پراکندگی).

(ج) اگر $\lambda = 0$ باشد، الگوریتم یادگیری مربوط به چه چیزی است؟ طبقه‌بندی است یا رگرسیون؟
اگر $\lambda = 0$ باشد، تابع هدف به صورت زیر در می‌آید:

$$J(\mathbf{w}) = -\ell(\mathbf{w}, D_{train})$$

که فقط تخمین حداکثر **likelihood** (MLE) برای رگرسیون لجستیک است — بدون منظم‌سازی. این هنوز هم طبقه‌بندی است، زیرا ما هنوز احتمال یک خروجی دودویی را از طریق تابع سیگموئید مدل می‌کنیم. بنابراین، وقتی $\lambda = 0$ ، الگوریتم مربوط به رگرسیون لجستیک غیرمنظم‌شده برای طبقه‌بندی دودویی است.

(د) افزایش λ چگونه بر لگاریتم **likelihood** آموزشی $\ell(\hat{\mathbf{w}}, D_{train})$ تأثیر می‌گذارد؟

با افزایش λ ، جمله منظم‌سازی $\lambda \|\mathbf{w}\|_2^2$ در تابع هدف $J(\mathbf{w})$ غالب‌تر می‌شود.

- این باعث می‌شود وزن‌های $\mathbf{w}$ از نظر بزرگی کوچک‌تر شوند.
- وزن‌های کوچک‌تر منجر به پیش‌بینی‌هایی نزدیک به ۰.۵ می‌شوند (زیرا $\sigma(\mathbf{w}^T \mathbf{x}) \rightarrow 0.5$ وقتی $\mathbf{w} \rightarrow 0$).
- پیش‌بینی‌های نزدیک به ۰.۵ به معنای کاهش اطمینان است، که لگاریتم **likelihood** را کاهش می‌دهد (زیرا $\log \sigma(y_i \mathbf{x}_i^T \mathbf{w})$ فقط وقتی کمتر منفی می‌شود که پیش‌بینی قاطع و صحیح باشد).

بنابراین، افزایش λ باعث کاهش لگاریتم **likelihood** آموزشی می‌شود.
بنابراین، با افزایش λ ، $\ell(\hat{\mathbf{w}}, D_{train})$ کاهش می‌یابد.

(ه) افزایش λ چگونه بر لگاریتم **likelihood** آزمونی $\ell(\hat{\mathbf{w}}, D_{test})$ تأثیر می‌گذارد؟

این بستگی دارد که آیا مدل دچار بیش‌برازش شده بود یا خیر.

- برای λ کوچک، مدل ممکن است داده‌های آموزشی را بیش‌برازش کند پس لگاریتم **likelihood** آموزشی بالا، اما تعمیم ضعیف پس لگاریتم **likelihood** آزمونی پایین.
- با افزایش λ ، منظم‌سازی بیش‌برازش را کاهش می‌دهد پس مدل ساده‌تر می‌شود و بهتر تعمیم می‌یابد پس لگاریتم **likelihood** آزمونی ممکن است اول افزایش یابد.
- با این حال، اگر λ خیلی بزرگ شود، مدل خیلی ساده می‌شود (کم‌برازش) پس لگاریتم **likelihood** آزمونی دوباره کاهش می‌یابد.

بنابراین، لگاریتم **likelihood** آزمونی معمولاً نسبت به λ یک منحنی U شکل (یا معکوس U) دارد: ابتدا افزایش، سپس کاهش.

بنابراین، افزایش λ ممکن است افزایش یا کاهش لگاریتم **likelihood** آزمونی را به دنبال داشته باشد — معمولاً یک بهینه وجود دارد که عملکرد آزمون را حداکثر می‌کند.

تمرین ۴

این تمرین به یک مسئله رگرسیون لجستیک دوبعدی با نقاط داده برچسب‌دار + و 0، همانند شکل ۱، می‌پردازد. هدف این است که درک کنیم چگونه انواع مختلف منظم‌سازی L_2 بر مرز تصمیم تأثیر می‌گذارند. مدل به صورت زیر است:

$$p(y = 1 | \mathbf{x}, \mathbf{w}) = \sigma(w_0 + w_1 x_1 + w_2 x_2)$$

که در آن $\sigma(a) = \frac{1}{1+e^{-a}}$ تابع سیگموید است. تابع هدف:

$$J(\mathbf{w}) = -\ell(\mathbf{w}, \mathcal{D}_{train})$$

که در آن $\ell(\mathbf{w}, \mathcal{D}_{train})$ لگاریتم likelihood روی مجموعه آموزشی است. ما از خواسته شده است که سه نوع منظم‌سازی L_2 را در نظر بگیریم و تأثیر آن‌ها بر مرز تصمیم را تحلیل کنیم — که با خطی تعریف می‌شود که در آن $p(y = 1 | \mathbf{x}, \mathbf{w}) = 0.5$ ، یا معادل آن، $w_0 + w_1 x_1 + w_2 x_2 = 0$.

(الف) بدون منظم‌سازی:

$$J(\mathbf{w}) = -\ell(\mathbf{w}, \mathcal{D}_{train})$$

در این حالت، ما likelihood را بدون هیچ جریمه‌ای بیشینه می‌کنیم. مرز تصمیم به گونه‌ای انتخاب می‌شود که بهترین جداکننده بین کلاس‌های + و 0 باشد. از شکل ۱ مشاهده می‌کنیم که کلاس + در ناحیه بالا-چپ و کلاس 0 در ناحیه پایین-راست خوشه‌بندی شده‌اند. یک جداکننده خطی باید دارای شیب منفی باشد — یعنی وقتی x_1 افزایش می‌یابد، x_2 باید کاهش یابد تا روی مرز باقی بماند. بنابراین، مرز تصمیم یک خط مانند زیر خواهد بود:

$$w_0 + w_1 x_1 + w_2 x_2 = 0 \quad \Rightarrow \quad x_2 = -\frac{w_1}{w_2} x_1 - \frac{w_0}{w_2}$$

برای شیب منفی، نیاز داریم $-\frac{w_1}{w_2} < 0$ ، بنابراین w_1 و w_2 باید علامت یکسانی داشته باشند. پس در حالت غیرمنظم‌شده، وزن‌های w_1 و w_2 احتمالاً علامت یکسانی خواهند داشت (هر دو مثبت یا هر دو منفی)، بسته به جهت‌گیری داده‌ها.

(ب) منظم‌سازی فقط بر جمله بایاس w_0 :

$$J(\mathbf{w}) = -\ell(\mathbf{w}, \mathcal{D}_{train}) + \lambda w_0^2$$

در اینجا، فقط جمله بایاس w_0 را جریمه می‌کنیم. این کار باعث می‌شود w_0 کوچک باشد، یعنی مرز تصمیم تمایل پیدا می‌کند که نزدیک‌تر به مبدأ باشد. با این حال، از آنجا که w_1 و w_2 منظم نشده‌اند، می‌توانند مقادیر بزرگی برای برازش خوب داده‌ها داشته باشند. شیب مرز تصمیم $(-w_1/w_2)$ تحت این منظم‌سازی تغییر نمی‌کند — فقط عرض از مبدأ به سمت صفر کشیده می‌شود. بنابراین، مرز تصمیم همچنان همان جهت‌گیری (همان نسبت $w_1 : w_2$) را خواهد داشت، اما موقعیتش به سمت مبدأ d_{sch} می‌شود. بنابراین، جهت (شیب) مرز تصمیم تغییر نمی‌کند، اما موقعیت (عرض از مبدأ) تحت تأثیر قرار می‌گیرد.

(ج) منظم سازی فقط بر w_1 :

$$J(\mathbf{w}) = -\ell(\mathbf{w}, D_{train}) + \lambda w_1^2$$

اکنون، فقط w_1 را جریمه می کنیم. این کار باعث می شود w_1 کوچک باشد. به یاد داشته باشید: شیب مرز تصمیم $-w_1/w_2$ است. اگر w_1 مجبور شود کوچک باشد، شیب به سمت صفر نزدیک می شود — یعنی مرز تصمیم **بیشتر افقی** می شود. چرا؟ زیرا اگر $w_1 \approx 0$ ، معادله مرز تصمیم تقریباً به این شکل در می آید:

$$w_0 + w_2 x_2 \approx 0 \quad \Rightarrow \quad x_2 \approx -\frac{w_0}{w_2}$$

که یک خط افقی است. اما توجه کنید: اگر w_1 خیلی کوچک باشد، مدل ممکن است نتواند کلاس ها را در جهت x_1 به خوبی جدا کند، بنابراین ممکن است بیشتر بر x_2 تکیه کند. پس، منظم سازی w_1 باعث می شود مرز تصمیم **بیشتر افقی** شود (کمتر وابسته به x_1).

(د) منظم سازی فقط بر w_2 :

$$J(\mathbf{w}) = -\ell(\mathbf{w}, D_{train}) + \lambda w_2^2$$

به طور مشابه، جریمه کردن w_2 باعث می شود که این وزن کوچک شود. شیب $-w_1/w_2$ است. اگر $w_2 \rightarrow 0$ ، شیب بسیار بزرگ (از نظر مقدار مطلق) می شود — یعنی مرز تصمیم **بیشتر عمودی** می شود. چرا؟ زیرا اگر $w_2 \approx 0$ ، معادله مرز تصمیم تقریباً به این شکل در می آید:

$$w_0 + w_1 x_1 \approx 0 \quad \Rightarrow \quad x_1 \approx -\frac{w_0}{w_1}$$

که یک خط عمودی است. دوباره، مدل کمتر به تغییرات در x_2 حساس می شود و بیشتر بر x_1 برای طبقه بندی تکیه می کند. پس، منظم سازی w_2 باعث می شود مرز تصمیم **بیشتر عمودی** شود (کمتر وابسته به x_2).

جمع بندی

نوع منظم سازی	تأثیر بر مرز تصمیم
بدون منظم سازی	جداکننده بهینه؛ شیب توسط داده تعیین می شود
فقط w_0	شیب ثابت، به سمت مبدأ منتقل می شود
فقط w_1	بیشتر افقی (کمتر وابسته به x_1)
فقط w_2	بیشتر عمودی (کمتر وابسته به x_2)

این نشان می دهد که چگونه منظم سازی ویژگی محور می تواند مدل را به سمت مرزهای تصمیم ساده تری سوق دهد که با محورهای خاصی همسو هستند — مفید وقتی باور داریم برخی ویژگی ها کم اهمیت تر یا پرنویزتر هستند.

تمرین ۵

این تمرین از ما می‌خواهد نشان دهیم که در طبقه‌بندی نایو بیز با ویژگی‌های دودویی، اطلاعات متقابل (MI) بین هر ویژگی و برجسب کلاس می‌تواند برای رتبه‌بندی ویژگی‌ها بر اساس قدرت تشخیصی آن‌ها استفاده شود و انتخاب ویژگی‌ها بر اساس MI بالا معادل است با انتخاب ویژگی‌هایی که تحت فرضیه نایو بیز، بیشترین اطلاعات را برای طبقه‌بندی فراهم می‌کنند.

پیش‌زمینه: نایو بیز با ویژگی‌های دودویی

در نایو بیز، فرض می‌کنیم:

$$p(y|\mathbf{x}) \propto p(y) \prod_{j=1}^D p(x_j|y)$$

برای ویژگی‌های دودویی $x_j \in \{0, 1\}$ ، هر $p(x_j|y)$ را به صورت توزیع برنولی مدل می‌کنیم:

$$p(x_j = 1|y) = \theta_{jy}, \quad p(x_j = 0|y) = 1 - \theta_{jy}$$

هدف انتخاب ویژگی، انتخاب مفیدترین ویژگی‌ها برای پیش‌بینی y است یعنی آنهایی که بیشترین اطلاعات را درباره برجسب کلاس فراهم می‌کنند.

اطلاعات متقابل (MI)

اطلاعات متقابل بین یک ویژگی X_j و برجسب کلاس Y به صورت زیر تعریف می‌شود:

$$I(X_j; Y) = \sum_{x_j \in \{0,1\}} \sum_y p(x_j, y) \log \frac{p(x_j, y)}{p(x_j)p(y)}$$

این مقدار نشان‌دهنده میزان اطلاعاتی است که X_j درباره Y (یا برعکس) فراهم می‌کند. MI بالاتر به معنای پیش‌بینی‌پذیری بیشتر ویژگی برای کلاس است.

چرا MI برای انتخاب ویژگی در نایو بیز مفید است؟

تحت فرضیه نایو بیز، ویژگی‌ها به شرط کلاس مستقل هستند: $X_j \perp X_k | Y$. این بدین معناست که لوگاریتم **likelihood** مشترک به صورت تمیزی عامل‌بندی می‌شود، و سهم هر ویژگی در پسین مستقل است.

بنابراین، قدرت تشخیصی هر ویژگی X_j فقط به توزیع شرطی خودش $p(x_j|y)$ و احتمال پیشین $p(y)$ بستگی دارد که دقیقاً همان چیزی است که MI اندازه‌گیری می‌کند.

در واقع، حداکثر کردن MI برای انتخاب ویژگی معادل است با انتخاب ویژگی‌هایی که likelihood را تحت مدل نایو بیز بیشینه می‌کنند زیرا MI به طور مستقیم میزان کمک هر ویژگی برای تشخیص بین کلاس‌ها را اندازه‌گیری می‌کند.

علاوه بر این، از آنجا که نایو بیز هر ویژگی را به صورت مستقل هنگام محاسبه پسین ارزیابی می‌کند، منطقی است که ویژگی‌ها را بر اساس MI فردی خودشان با کلاس رتبه‌بندی کنیم نه با در نظر گرفتن تعاملات (که نایو بیز در هر حال نادیده می‌گیرد).

نتیجه گیری

در نایو بیز با ویژگی‌های دودویی، رتبه‌بندی ویژگی‌ها بر اساس اطلاعات متقابل (MI) با برچسب کلاس، روشی منطقی برای انتخاب ویژگی است، زیرا:

- MI به طور مستقیم میزان اطلاعاتی را که هر ویژگی درباره کلاس فراهم می‌کند، اندازه‌گیری می‌کند.
 - تحت نایو بیز، ویژگی‌ها به شرط کلاس مستقل هستند بنابراین می‌توانیم آن‌ها را به صورت فردی ارزیابی کنیم.
 - انتخاب ویژگی‌های MI بالا عملکرد طبقه‌بندی را با تمرکز بر ویژگی‌های تشخیصی‌تر بهبود می‌بخشد.
- بنابراین، MI معیار طبیعی‌ای برای انتخاب ویژگی در طبقه‌بندی‌های نایو بیز است.

تمرین ۶

فرض کنید یک مدل ترکیبی از دو کلاس وجود دارد که در آن هر کلاس با احتمال π_m ($m = 0$ یا 1) انتخاب می‌شود. برای هر کلاس m ، توزیع احتمال مشاهده داده x_n به صورت $p(x_n|m)$ داده شده است. هدف این است که لگاریتم likelihood ($\log$ -likelihood) برای داده x_n را تحت این مدل ترکیبی محاسبه کنیم.

محاسبه $\log$ -likelihood

احتمال مشاهده داده x_n تحت مدل ترکیبی برابر است با:

$$p(x_n) = \sum_{m=0}^1 p(x_n|m) \cdot p(m)$$

که در آن $p(m) = \pi_m$ احتمال انتخاب کلاس m است. بنابراین:

$$p(x_n) = \pi_0 \cdot p(x_n|0) + \pi_1 \cdot p(x_n|1)$$

حال، لگاریتم likelihood برای داده x_n برابر است با:

$$\log p(x_n) = \log (\pi_0 \cdot p(x_n|0) + \pi_1 \cdot p(x_n|1))$$

توضیح

این عبارت نشان می‌دهد که در یک مدل ترکیبی، احتمال یک داده به صورت میانگین وزنی احتمالات شرطی تحت هر کلاس محاسبه می‌شود وزن‌ها همان احتمالات prior کلاس‌ها (π_0 و π_1) هستند. لگاریتم این میانگین وزنی را نمی‌توان ساده‌تر کرد بنابراین، $\log$ -likelihood مستقیماً به صورت بالا محاسبه می‌شود.

نکته مهم

در برخی موارد (مثلاً در الگوریتم EM) به جای log-likelihood کلی، از log-likelihood شرطی با توجه به متغیرهای پنهان (کلاس‌ها) استفاده می‌شود. اما در اینجا، از ما خواسته شده است که log-likelihood کلی را محاسبه کنیم یعنی احتمال داده بدون دانستن کلاس آن. بنابراین، جواب نهایی:

$$\log p(x_n) = \log (\pi_0 \cdot p(x_n|0) + \pi_1 \cdot p(x_n|1))$$

تمرین ۷

فرض کنید یک مسئله طبقه‌بندی دودویی داریم. هدف این است که با استفاده از SVM یک مرز خطی را پیدا کنیم که داده‌ها را با حداکثر حاشیه (margin) جدا کند. داده‌ها شامل N نمونه $\{x_n, y_n\}$ هستند، که در آن $x_n \in \mathbb{R}^d$ و $y_n \in \{-1, +1\}$.

۱. فرم اولیه (primal) SVM

هدف اصلی SVM پیدا کردن بردار وزن $\mathbf{w}$ و بایاس b است به گونه‌ای که: تمام نقاط داده به درستی طبقه‌بندی شوند: $y_n(\mathbf{w}^\top \mathbf{x}_n + b) \geq 1$ - حاشیه (فاصله بین مرز و نزدیک‌ترین نقاط) حداکثر شود. حاشیه برابر است با $\frac{2}{\|\mathbf{w}\|}$. بنابراین، حداکثر کردن حاشیه معادل است با حداقل کردن $\frac{1}{2}\|\mathbf{w}\|^2$. پس فرم اولیه SVM (primal) به صورت زیر است:

$$\min_{\mathbf{w}, b} \quad \frac{1}{2}\|\mathbf{w}\|^2$$

to subject $y_n(\mathbf{w}^\top \mathbf{x}_n + b) \geq 1, \quad \forall n = 1, \dots, N$

این یک مسئله بهینه‌سازی محدب است.

۲. فرم دوگان (dual) و تکنیک لاگرانژ

با استفاده از ضرایب لاگرانژ $\alpha_n \geq 0$ ، تابع لاگرانژ را می‌نویسیم:

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\mathbf{w}\|^2 - \sum_{n=1}^N \alpha_n [y_n(\mathbf{w}^\top \mathbf{x}_n + b) - 1]$$

مشتق‌گیری نسبت به $\mathbf{w}$ و b و صفر قرار دادن آن‌ها منجر به روابط زیر می‌شود:

$$\mathbf{w} = \sum_{n=1}^N \alpha_n y_n \mathbf{x}_n$$

$$\sum_{n=1}^N \alpha_n y_n = 0$$

با جایگذاری این عبارات در تابع لاگرانژ، فرم دوگان (dual) به دست می‌آید:

$$\max_{\boldsymbol{\alpha}} \quad \sum_{n=1}^N \alpha_n - \frac{1}{2} \sum_{n=1}^N \sum_{m=1}^N \alpha_n \alpha_m y_n y_m \mathbf{x}_n^\top \mathbf{x}_m$$

$$\text{to subject } \alpha_n \geq 0, \quad \sum_{n=1}^N \alpha_n y_n = 0$$

این فرم دوگان فقط به ضرب داخلی بردارهای ورودی $\mathbf{x}_n^\top \mathbf{x}_m$ بستگی دارد که امکان استفاده از تکنیک هسته (kernel) (trick) را فراهم می‌کند.

۳. محاسبات و قیود کامل

در فرم دوگان، تنها متغیرهای بهینه‌سازی α_n هستند. این متغیرها مثبت هستند و تحت قید $\sum \alpha_n y_n = 0$ قرار دارند.

نقطه‌هایی که $\alpha_n > 0$ دارند، "بردارهای پشتیبان" (support vectors) نامیده می‌شوند چون تنها این نقاط در ساخت مرز تصمیم نقش دارند. مرز تصمیم نهایی به صورت زیر است:

$$f(\mathbf{x}) = \sum_{n=1}^N \alpha_n y_n \mathbf{x}_n^\top \mathbf{x} + b$$

که فقط بر روی بردارهای پشتیبان غیرصفر است.

۴. تعمیم SVM با فرمول‌بندی دوکلاسه

در حالت کلی، برای تعمیم SVM به مواردی که داده‌ها به طور کامل قابل جدا کردن نیستند، یک متغیر شل (slack variable) $\xi_n \geq 0$ معرفی می‌شود و فرم اولیه به صورت زیر اصلاح می‌شود:

$$\min_{\mathbf{w}, b, \xi} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{n=1}^N \xi_n$$

$$\text{to subject } y_n(\mathbf{w}^\top \mathbf{x}_n + b) \geq 1 - \xi_n, \quad \xi_n \geq 0$$

که در آن C یک پارامتر تنظیم (regularization) است که تعادل بین حاشیه و خطا را کنترل می‌کند. همچنین، با استفاده از تکنیک هسته، می‌توان SVM را برای داده‌های غیرخطی به کار برد:

$$f(\mathbf{x}) = \sum_{n=1}^N \alpha_n y_n K(\mathbf{x}_n, \mathbf{x}) + b$$

که در آن $K(\mathbf{x}_n, \mathbf{x})$ یک تابع هسته (مثل RBF یا چندجمله‌ای) است. بنابراین، SVM یک الگوریتم قدرتمند برای طبقه‌بندی خطی و غیرخطی است که بر اساس حداکثر کردن حاشیه و بهینه‌سازی محدب کار می‌کند.

تمرین ۸

فرض کنید یک مسئله طبقه‌بندی دودویی داریم با داده‌های $\{x_n, y_n\}$ ، که در آن $x_n \in \mathbb{R}^d$ و $y_n \in \{-1, +1\}$. هدف این است که خواص الگوریتم پرسپترون را بررسی کنیم.

۱. قانون به‌روزرسانی پرسپترون

الگوریتم پرسپترون یک جدای‌ساز خطی با وزن‌های $\mathbf{w}$ و بایاس b را یاد می‌گیرد. قانون به‌روزرسانی آن به صورت زیر است:

– اگر نمونه x_n اشتباه طبقه‌بندی شده باشد (یعنی $y_n(\mathbf{w}^\top x_n + b) \leq 0$)، آنگاه:

$$\mathbf{w} \leftarrow \mathbf{w} + y_n x_n$$

$$b \leftarrow b + y_n$$

این به‌روزرسانی به گونه‌ای است که مرز تصمیم به سمت طبقه صحیح جابجا می‌شود. این الگوریتم فقط وقتی همگرا می‌شود که داده‌ها ****خطی جداپذیر**** باشند. در غیر این صورت، ممکن است هرگز متوقف نشود.

۲. فرض‌های لازم برای همگرایی

برای همگرایی الگوریتم پرسپترون، دو فرض مهم وجود دارد:

- **خطی جداپذیری:** باید یک جدای‌ساز خطی وجود داشته باشد که تمام داده‌ها را به درستی طبقه‌بندی کند.
- **نرمال‌سازی داده‌ها:** در برهان همگرایی، معمولاً فرض می‌شود که $\|x_n\| \leq R$ (یعنی داده‌ها در یک توپ با شعاع محدود قرار دارند).

در این حالت، الگوریتم پس از تعداد متناهی از به‌روزرسانی‌ها همگرا می‌شود حتی اگر داده‌ها با نویز آلوده باشند (به شرطی که هنوز خطی جداپذیر باشند).

۳. پیاده‌سازی در sklearn

در کتابخانه 'sklearn' یک پیاده‌سازی کلاسیک از پرسپترون وجود دارد:

```
Perceptron import sklearn.linear_model from
random_state=42) ,eta0=1.0 ,Perceptron(max_iter=1000 = clf
y_train) ,clf.fit(X_train
```

ویژگی‌های اصلی:

- **max_iter:** حداکثر تعداد دوره‌های آموزش برای جلوگیری از حلقه‌های بی‌نهایت در داده‌های غیرخطی جداپذیر.

- **eta0:** نرخ یادگیری در پرسپترون کلاسیک معمولاً ۱ است.

- **random_state:** برای قابلیت تکرار ترتیب داده‌ها را تصادفی می‌کند.

نکته مهم: در 'sklearn' پرسپترون به صورت پیش‌فرض با یک جمله تنظیم (regularization) کوچک (مثل L_2) همراه است بنابراین دقیقاً معادل پرسپترون کلاسیک نیست.

۴. مقایسه با SVM و کاهش خطا

الگوریتم پرسپترون یک مدل خطی ساده است که فقط روی ****خطای طبقه‌بندی**** تمرکز دارد نه روی حاشیه یا دقت در احتمالات.

در مقابل، SVM به دنبال ****حداکثر کردن حاشیه**** است که منجر به تعمیم بهتر می‌شود. همچنین، پرسپترون می‌تواند در داده‌های غیرخطی جداپذیر به حلقه بی‌نهایت بیفتد در حالی که SVM با استفاده از هسته‌ها (kernel) می‌تواند داده‌های غیرخطی را جدا کند. بنابراین، پرسپترون برای مسائل ساده و خطی جداپذیر مناسب است اما برای کاربردهای عملی، معمولاً SVM یا Regression Logistic ترجیح داده می‌شوند. در نهایت، پرسپترون یک الگوریتم تاریخی و آموزشی است که اساس یادگیری عمیق (Deep Learning) را تشکیل می‌دهد اما در عمل، با الگوریتم‌های پیشرفته‌تر جایگزین شده است.